

Relatório da distribuição de avalanches em alto T_s

Modelo com corte estendido, seleção de s_{min} e resposta aos revisores

Manuscrito: ER12738, *Scaling behaviors in simulated collagen fibrils*

Spec de revisão: GitHub issue #1

Ticket estatístico: GitHub issue #5

1. Resultado principal

As caudas das avalanches nas quatro condições de maior relaxação superficial são bem descritas por uma distribuição discreta conjunta com fator de potência e corte exponencial estendido:

$$p(s \mid s \geq s_{min}) = \frac{s^{-\alpha} \exp[-(s/s_c)^\beta]}{\sum_{k=s_{min}}^{\infty} k^{-\alpha} \exp[-(k/s_c)^\beta]}.$$

O limite inferior foi estimado para esse próprio modelo, em vez de ser herdado do ajuste de potência pura. O resultado é

$$s_{min} = 29.$$

No suporte $s \geq 29$, o ajuste conjunto fornece

$$\alpha = 2.534, \quad \beta = 2.547,$$

com uma escala de corte s_c entre aproximadamente 212 e 243, dependendo de T_s . Condiicionado ao suporte selecionado, o modelo não é rejeitado pelo bootstrap de fibrilas ($p = 0.981$) nem pelo diagnóstico paramétrico iid ($p = 0.558$).

Esse resultado sustenta uma descrição comum e de escala finita para as caudas de alto T_s . A forma contém um fator de potência bem definido antes do corte, mas não é uma lei de potência pura: o valor $\beta > 2$ representa uma supressão pronunciada dos eventos maiores.

2. Dados e definição de avalanche

A análise utiliza os dados completos de Data__avalanches__all__fibrils:

- 50 geometrias de fibrila independentes por T_s ;
- 1.000 realizações de ruptura por fibrila;
- eventos de dez condições de relaxação superficial;
- 300.538.797 avalanches locais pré-terminais no total.

Uma avalanche é um componente espacialmente conexo removido durante um único passo de força fixa. Componentes desconectados no mesmo passo são eventos distintos. Eventos $s = 1$ permanecem válidos no corpo da distribuição, mas não pertencem à cauda selecionada. Não há agregação temporal, e o passo de ruptura terminal é excluído da análise primária.

As realizações feitas sobre a mesma fibrila compartilham geometria, e os eventos de uma mesma realização compartilham o histórico de dano. Por isso, a fibrila é a unidade independente usada na inferência estrutural.

3. Como $s_{min} = 29$ foi determinado

O suporte foi escolhido pela mesma ideia central usada por Clauset para selecionar o início de uma cauda: ajustar o modelo em cada limite candidato e minimizar a discrepância KS.

Como o modelo é simultâneo para quatro condições, foi necessário definir uma estatística conjunta. O procedimento foi:

1. considerar todos os valores inteiros comuns de $s_{min} = 1$ até 110;
2. exigir pelo menos 1.000 eventos em cada uma das quatro caudas;
3. para cada candidato, reajustar por máxima verossimilhança os seis parâmetros do modelo: α , β e quatro valores de s_c ;
4. calcular um KS para cada condição;
5. usar como discrepância conjunta o maior dos quatro valores de KS;
6. selecionar o s_{min} que minimiza essa discrepância simultânea.

Formalmente,

$$\hat{s}_{min} = \operatorname{argmin}_{s_{min}} \max_{T_s} D_{KS}(T_s, s_{min}).$$

Os candidatos mais próximos do mínimo foram:

s_{min}	maior KS
27	0.007989
28	0.008071
29	0.007279
30	0.008712
31	0.008886

Assim, $s_{min} = 29$ não é uma escolha visual nem o máximo dos limites encontrados para a potência pura. É o limite estimado para a distribuição efetivamente adotada.

O critério do maior KS foi escolhido porque o modelo só deve ser considerado comum se descrever adequadamente todas as quatro condições. Uma média dos quatro KS poderia esconder uma condição com ajuste ruim.

4. Relação com a metodologia de Clauset

Clauset, Shalizi e Newman propõem três etapas distintas:

1. estimar os parâmetros e o início da cauda;
2. testar a qualidade absoluta do ajuste;
3. comparar a hipótese com distribuições concorrentes.

Esses princípios foram aplicados da seguinte forma:

- os tamanhos inteiros foram analisados sem binning;
- a distribuição foi normalizada no suporte discreto infinito;
- os parâmetros foram estimados por máxima verossimilhança;
- s_{min} foi escolhido objetivamente por minimização do KS;
- os ajustes foram avaliados por bootstrap com reestimação dos parâmetros;
- um p acima de 0.10 foi interpretado como compatibilidade, não como demonstração matemática de que o modelo é único.

Para a potência pura, foi usado o protocolo discreto canônico de Clauset: normalização por zeta de Hurwitz, escolha de s_{min} e α , teste semiparamétrico e comparação com alternativas. Esse teste mostrou que a potência pura não é uma descrição robusta das dez condições.

O modelo com corte estendido não é a hipótese canônica de Clauset, mas é avaliado com a mesma lógica MLE–KS–bootstrap. A adaptação adicional é o ajuste simultâneo das quatro condições e a inferência por blocos de fibrilas.

Os valores de qualidade de ajuste reportados abaixo são condicionais ao $s_{min} = 29$ selecionado. O bootstrap reajusta os seis parâmetros, mantendo o suporte. A busca completa de s_{min} está registrada em `xmin_scan.csv`, permitindo auditar a seleção e realizar posteriormente uma calibração que repita também a escolha do suporte em cada réplica.

5. Ajuste conjunto

As estimativas e os intervalos de 95% obtidos pelo bootstrap de fibrilas são

$$\alpha = 2.534 [2.438, 2.615], \quad \beta = 2.547 [2.128, 2.980].$$

T_s	eventos $s \geq 29$	s_c (IC 95% por fibrilas)	KS	p_{block}
512	14.681	242.79 [207.60, 269.51]	0.00728	0.610
1024	15.027	217.39 [192.98, 239.01]	0.00657	0.700

CCDFs empíricas e ajuste conjunto do modelo com corte estendido para os quatro valores altos de T_s .

Figure 1: CCDFs empíricas e ajuste conjunto do modelo com corte estendido para os quatro valores altos de T_s .

CCDFs empíricas e ajustes individuais do modelo com corte estendido para cada valor alto de T_s .

Figure 2: CCDFs empíricas e ajustes individuais do modelo com corte estendido para cada valor alto de T_s .

T_s	eventos $s \geq 29$	s_c (IC 95% por fibrilas)	KS	p_{block}
4096	15.642	211.59 [179.67, 240.61]	0.00726	0.643
8192	14.597	243.40 [212.73, 270.36]	0.00687	0.711

O teste simultâneo utiliza o maior KS entre as quatro condições e reajusta os seis parâmetros em cada uma das 999 amostras de fibrilas:

$$p_{joint,block} = 0.981.$$

Figura 1 — Ajuste conjunto no suporte $s \geq 29$. Os pontos azuis são as CCDFs empíricas condicionais e as linhas laranjas são o modelo discreto ajustado. O modelo compartilha $\alpha = 2.534$ e $\beta = 2.547$ entre as quatro condições, estimando um s_c específico para cada T_s . Os eixos são logarítmicos.

O modelo conjunto, portanto, é compatível com a variabilidade observada entre as 50 geometrias. Além disso, os quatro ajustes separados do corte estendido também não são rejeitados:

T_s	α	β	s_c	p_{block}
512	2.591	3.234	256.13	0.645
1024	2.506	2.428	211.87	0.205
4096	2.559	2.465	215.31	0.655
8192	2.484	2.359	231.81	0.810

Figura 2 — Ajustes individuais no suporte comum $s \geq 29$. Em cada painel, α , β e s_c são estimados independentemente para a condição correspondente. Os pontos azuis representam as CCDFs empíricas condicionais e as linhas laranjas representam os ajustes.

Isso elimina a dificuldade encontrada no suporte anterior $s \geq 8$, no qual os ajustes separados de $T_s = 1024$ e 8192 eram rejeitados.

6. Sensibilidade iid

Como diagnóstico complementar, foram geradas 999 amostras paramétricas do modelo conjunto, tratando os 59.947 eventos da cauda como iid. Os seis parâmetros foram reajustados em cada amostra, com suporte fixo em 29.

O resultado conjunto foi

$$p_{joint,iid} = 0.558.$$

Os resultados condicionais foram:

T_s	p_{iid}
512	0.218
1024	0.304
4096	0.176
8192	0.245

Todos permanecem acima do limiar de 0.10. Portanto, o modelo selecionado não depende exclusivamente da maior tolerância do bootstrap por fibrilas: ele também é compatível com o diagnóstico iid, muito mais sensível a pequenas discrepâncias.

7. Interpretação estatística e física

O resultado permite afirmar que as caudas de alto T_s compartilham uma forma estatística comum, composta por:

- decaimento inicial aproximadamente algébrico, controlado por $\alpha \simeq 2.53$;
- escala característica $s_c \simeq 212\text{--}243$;
- corte final pronunciado, controlado por $\beta \simeq 2.55$.

Essa parametrização é consistente nas quatro condições e nos dois diagnósticos de qualidade do ajuste. Ela fornece um modelo compacto para comparar como a morfologia da fibrila se relaciona com a estatística de dano.

O significado de α deve permanecer ligado a essa distribuição com corte. Ele não é diretamente o expoente 5/2 de uma lei de potência ELS e não identifica, isoladamente, uma classe de compartilhamento de carga.

Também não é necessário invocar SOC para interpretar o resultado. A conclusão estatística é suficientemente forte por si: as avalanches de alto T_s possuem uma cauda comum com prefator de potência e escala máxima característica na dinâmica de fratura dirigida.

8. Resposta recomendada ao revisor

R1-2 — adequação da distribuição e método de Clauset

We thank the Referee for requesting a rigorous distributional analysis. We reanalyzed the raw, unbinned integer avalanche sizes from 50 independent fibril geometries and 1,000 rupture realizations per geometry at each T_s . A pure discrete power law was evaluated using exact maximum likelihood, KS-based lower-cutoff selection, semi-parametric goodness-of-fit testing, and comparisons with alternative distributions following Clauset, Shalizi, and Newman. The pure power law was not supported consistently across conditions.

We then evaluated a discrete power-law factor with a stretched-exponential cutoff, $p(s) \propto s^{-\alpha} \exp[-(s/s_c)^\beta]$, for the four high- T_s conditions. Importantly, the common lower cutoff was estimated for this model itself. We refitted the six-parameter joint model at every common integer candidate with at least 1,000 events per condition and selected the value minimizing the maximum KS across conditions, obtaining $s_{min} = 29$. The fitted common parameters are $\alpha = 2.534$ and $\beta = 2.547$, with condition-specific $s_c \simeq 212$ –243.

Conditional on the selected support, the joint model is compatible with both a 999-replicate fibril-block goodness-of-fit test ($p = 0.981$) and a 999-replicate iid parametric sensitivity test ($p = 0.558$). All four condition-specific fits are also not rejected. We therefore describe the high- T_s tails as a common finite-scale distribution with a power-law factor and a pronounced stretched-exponential cutoff, rather than as a pure or scale-free power law.

R1-3 — interpretação do expoente

We agree that an exponent above the equal-load-sharing value should not be interpreted as evidence for increasingly global load sharing. In the revised analysis, $\alpha \simeq 2.534$ is the prefactor parameter of the fitted finite-cutoff distribution on $s \geq 29$. We do not identify it as a universal critical exponent or use its difference from $5/2$ to infer a load-sharing universality class. The enlarged ensemble contains 50 independent fibril geometries per condition, and uncertainty is quantified by resampling those geometries as blocks.

R2-3 e R2-4 — definição de avalanche e SOC

We define a local avalanche operationally as one nearest-neighbor connected component removed at a fixed force step; disconnected components at the same force are counted separately. This spatial damage observable does not imply a local elastic stress-redistribution kernel. We also removed the SOC interpretation because the fracture

process is externally driven, irreversible, and has no healing mechanism. The result is described as local-avalanche statistics in driven disordered fracture.

9. Formulação recomendada para o manuscrito

For $T_s \geq 512$, the preterminal local-avalanche tails are compatible with a common discrete finite-scale distribution $p(s) \propto s^{-2.534} \exp[-(s/s_c)^{2.547}]$ above the model-selected cutoff $s_{min} = 29$, with $s_c \simeq 212$ –243 depending on T_s . Conditional goodness-of-fit tests do not reject the joint model under either fibril-block inference ($p = 0.981$) or an iid parametric sensitivity analysis ($p = 0.558$). The result supports a common power-law factor with a pronounced finite cutoff, rather than a pure or scale-free power law.

10. Evidência e reprodutibilidade

- Resumo dos resultados atuais;
- Busca completa de $s_{min} = 1, \dots, 110$;
- Ajuste conjunto e bootstrap de fibrilas;
- Diagnóstico iid;
- CCDFs condicionais e ajuste conjunto;
- Resumo metodológico de Clauset;
- Fonte metodológica local.

O seletor está implementado em `Code/Data_analysis/clauset_hierarchical/stretched_cutoff.py`. O programa `run_stretched_cutoff_high_ts.py` seleciona s_{min} automaticamente quando `-xmin` não é informado e permite reproduzir também análises condicionais em um suporte fixado.